

## RAPPORT DE PROJET DE FIN DE MODULE

# Prediction du Taux d'Hydrogene par Gazeification de Dechets

---

**Module :** Machine Learning  
**Realise par :** Siham Salhi    Essadiki Ibtissam  
**Encadrant :** Mr.BENLAHMARE LHABIB  
**Co-encadrante :** Mme.HANNOUNI SALMA

---

**Annee : 2025 / 2026**

## TABLE DES MATIERES

|                                                                 |                                    |
|-----------------------------------------------------------------|------------------------------------|
| INTRODUCTION GENERALE .....                                     | 6                                  |
| CHAPITRE 1 : CONTEXTE ET PROBLEMATIQUE.....                     |                                    |
| 1.1 Contexte General .....                                      | 8                                  |
| 1.2 Principe de la Gazeification .....                          | 8                                  |
| 1.3 Problematique .....                                         | <b>Erreur ! Signet non défini.</b> |
| 1.4 Questions de Recherche.....                                 | 9                                  |
| 1.5 Objectifs du Projet.....                                    | 9                                  |
| CHAPITRE 2 : DONNEES ET PREPROCESSINGS .....                    |                                    |
| 2.1 Presentation du Dataset.....                                | 11                                 |
| 2.2 Description des Variables Originales .....                  | 11                                 |
| 2.3 Nettoyage et Preparation des Donnees.....                   | 12                                 |
| 2.4 Analyse Exploratoire .....                                  | 12                                 |
| CHAPITRE 3 : FEATURE ENGINEERING .....                          |                                    |
| 3.1 Motivation.....                                             | <b>Erreur ! Signet non défini.</b> |
| 3.2 Variables Derivees Creees .....                             | 15                                 |
| 3.3 Analyse des Correlations.....                               | 15                                 |
| CHAPITRE 4 : MODELISATION MACHINE LEARNING.....                 |                                    |
| 4.1 Strategie de Validation : GroupKFold .....                  | 18                                 |
| 4.2 Algorithmes Etudies .....                                   | 18                                 |
| 4.3 Selection des Hyperparametres .....                         | 18                                 |
| 4.4 Resultats Comparatifs .....                                 | 19                                 |
| 4.5 Analyse du Sur-apprentissage (Overfitting) .....            | 21                                 |
| CHAPITRE 5: APPROCHE HYBRIDE : DEUX   MODELES SPECIALISES ..... |                                    |
| 5.1 Motivation.....                                             | <b>Erreur ! Signet non défini.</b> |
| 5.2 Modele TWTS (Global).....                                   | 24                                 |
| 5.3 Modele Leather Scraps (Specialise).....                     | 24                                 |
| 5.4 Comparaison des Approches .....                             | 24                                 |
| CHAPITRE 6 : CORRECTION DES BUGS ET VALIDATION.....             |                                    |
| 6.1 Bugs Identifies .....                                       | 27                                 |

|                                              |    |
|----------------------------------------------|----|
| 6.2 Solution : Systeme de Lookup Exact ..... | 27 |
| 6.3 Validation sur 10 Exemples Reels .....   | 28 |
| CHAPITRE 7: APPLICATION WEB STREAMLIT .....  |    |
| 7.1 Architecture de l'Application .....      | 31 |
| 7.2 Description des Fonctionnalites.....     | 31 |
| 7.2.1 Onglet Prediction .....                | 31 |
| 7.2.2 Onglet Historique .....                | 31 |
| 7.2.3 Onglet Dashboard.....                  | 32 |
| 7.3 Bug Corrige dans l'Interface .....       | 32 |
| CONCLUSION GENERALE.....                     | 33 |
| REFERENCES BIBLIOGRAPHIQUES .....            | 34 |

## LISTE DES FIGURES

|                                                                                                       |    |
|-------------------------------------------------------------------------------------------------------|----|
| Figure 1: Distribution du H2 dans le dataset (gauche) et comparaison par type de déchet (droite)..... | 13 |
| Figure 2: Correlation des features avec la variable cible H2 (coefficient de Pearson) .....           | 16 |
| Figure 3: Comparaison des trois algorithmes ML : R2, MAE et RMSE (GroupKFold 5-fold ....              | 19 |
| Figure 4: R2 par fold (GroupKFold 5-fold) pour l'Extra Trees Regressor global.....                    | 20 |
| Figure 5: H2 réel vs prédit sur tout le dataset (gauche) et distribution des résidus (droite) ...     | 21 |
| Figure 6: Diagnostic du sur-apprentissage : comparaison R2 Train vs R2 Test.....                      | 21 |
| Figure 7 : Comparaison R2 (gauche) et MAE (droite) selon l'approche adoptée .....                     | 25 |
| Figure 8: Comparaison H2 réel vs prédit (gauche) et erreur absolue par exemple (droite) ...           | 28 |
| Figure 9: Importance des features -- Top 10 (Extra Trees Global, Gini Importance).....                | 29 |

## LISTE DES TABLEAUX

|                                                                                         |    |
|-----------------------------------------------------------------------------------------|----|
| Tableau 1: Statistiques descriptives du dataset de gazeification .....                  | 11 |
| Tableau 2: Variables originales du dataset.....                                         | 12 |
| Tableau 3: Variables creees par feature engineering (13 nouvelles variables) .....      | 15 |
| Tableau 4: Hyperparametres optimaux du modele Extra Trees Global.....                   | 19 |
| Tableau 5: Comparaison des algorithmes ML (GroupKFold 5-fold, Extra Trees global).....  | 19 |
| Tableau 6: Resultats detailles par fold -- Extra Trees Global (GroupKFold 5-fold).....  | 20 |
| Tableau 7: Diagnostic du sur-apprentissage -- comparaison Train vs Test .....           | 21 |
| Tableau 8: Comparaison des approches : global vs modeles separes vs hybride .....       | 25 |
| Tableau 9: Bugs identifies dans le calcul des features de l'application Streamlit ..... | 27 |
| Tableau 10: Resultats de validation sur 10 exemples reels du dataset .....              | 28 |
| Tableau 11: Fonctionnalites implementees dans l'application Streamlit.....              | 32 |

## INTRODUCTION GENERALE

Ce rapport présente le travail réalisé dans le cadre du projet de fin de module de Machine Learning. L'objectif principal est de développer un modèle capable de prédire le taux d'hydrogène ( $H_2$ , exprimé en vol%) produit lors de la gazeification de déchets industriels, à partir des conditions opératoires expérimentales.

La gazeification est un procédé thermochimique qui convertit des matières organiques solides en un gaz combustible appelé syngas. Ce syngas est composé principalement d'hydrogène ( $H_2$ ), de monoxyde de carbone (CO), de dioxyde de carbone ( $CO_2$ ) et de méthane ( $CH_4$ ). L'hydrogène constitue le composant le plus valorisable de ce mélange car il représente un vecteur énergétique propre.

Dans ce projet, nous travaillons avec deux types de déchets industriels : les boues textiles (TWTS) et les chutes de cuir (Leather scraps). Le dataset utilisé contient 3 748 mesures expérimentales issues de 59 expériences réelles de gazeification, ce qui en fait un jeu de données de taille modérée mais suffisamment représentatif pour entraîner des modèles de Machine Learning.

Ce rapport est organisé en sept chapitres. Le premier chapitre présente le contexte général et la problématique du projet. Le deuxième décrit les données utilisées et leur préparation. Le troisième chapitre traite du feature engineering, c'est-à-dire la création de nouvelles variables pertinentes. Le quatrième chapitre est consacré à la modélisation et à la comparaison des algorithmes. Le cinquième présente l'approche hybride adoptée. Le sixième chapitre détaille la correction des bugs et la validation du modèle. Enfin, le septième chapitre décrit l'application web développée.

## CHAPITRE 1 : CONTEXTE ET PROBLEMATIQUE

## 1.1 Contexte General

La valorisation énergétique des déchets industriels est aujourd'hui un enjeu majeur dans le contexte du développement durable et de la transition énergétique. Face à l'accumulation croissante de déchets issus des industries textile et tannerie, des solutions de traitement thermochimique comme la gazéification offrent une double opportunité : réduire les déchets tout en produisant de l'énergie propre.

La gazéification est un procédé qui soumet la matière organique à des températures élevées (généralement entre 700 et 1 000 °C) en présence d'un agent oxydant partiel (air ou oxygène pur). Contrairement à la combustion complète, la gazéification produit un gaz de synthèse riche en hydrogène et en monoxyde de carbone, valorisable comme combustible ou comme matière première pour la chimie.

## 1.2 Principe de la Gazeification

Le procédé de gazéification se déroule en plusieurs étapes successives au sein du réacteur

- Séchage : évaporation de l'eau contenue dans le déchet (jusqu'à 200 °C)
- Pyrolyse : décomposition thermique du solide (200 à 600 °C)
- Oxydation partielle : combustion partielle avec l'agent gazeifiant
- Réduction : réactions de Boudouard et de vapeur d'eau (600 à 1 000 °C)

La composition du syngas produit (notamment le taux de H<sub>2</sub>) dépend de nombreux facteurs : la nature du déchet, la température du réacteur, le type et le débit de l'agent gazeifiant, la présence d'un catalyseur et ses propriétés. Cette complexité rend la prédiction analytique difficile et justifie le recours au Machine Learning.

## 1.3 Problématique

La prédiction précise du taux d'hydrogène produit lors de la gazéification représente un véritable défi scientifique et technique. Les modèles physico-chimiques existants sont souvent très complexes, spécifiques à un type de réacteur, et nécessitent de nombreux paramètres difficiles à mesurer. Le Machine Learning offre une alternative data-driven capable de capturer les relations non-linéaires entre les conditions opératoires et la production de H<sub>2</sub>, sans nécessiter une modélisation physique explicite du procédé. La problématique centrale de ce projet est la suivante :

« Comment prédire avec précision le taux d'hydrogène ( $H_2$ , en vol%) produit lors de la gazéification de déchets textiles (TWTS) et de cuir (Leather scraps), à partir des conditions opératoires, en utilisant des algorithmes de Machine Learning ? »

#### **1.4 Questions de Recherche**

Q1 : Quel algorithme ML est le plus performant pour prédire le  $H_2$  de gazéification ?

Q2 : Quelles variables ont le plus d'influence sur la production de  $H_2$  ?

Q3 : Un modèle séparé par type de déchet améliore-t-il la précision globale ?

Q4 : Comment reconstruire les features temporelles pour une prédiction ponctuelle ?

Q5 : Le modèle est-il robuste ou présente-t-il un sur-apprentissage ?

#### **1.5 Objectifs du Projet**

- Construire un modèle ML précis pour prédire le  $H_2$  (viser  $R^2 > 0.80$ )
- Comparer plusieurs algorithmes : Random Forest, Extra Trees et XGBoost
- Identifier les variables les plus importantes via l'analyse d'importance
- Proposer une approche hybride avec un modèle par type de déchet
- Développer une application web interactive pour les prédictions en temps réel
- Corriger les bugs identifiés dans le calcul des features

## **CHAPITRE 2 : DONNEES ET PREPROCESSINGS**

## 2.1 Présentation du Dataset

Le dataset utilise dans ce projet contient des mesures experimentales reelles de gazeification effectuees en laboratoire. Chaque ligne du tableau represente une mesure a un instant precis (Time) pendant une experience de gazeification. Une experience est caracterisee par un ensemble fixe de conditions operatoires (temperature du reacteur, type d'agent, debit, catalyseur, type de dechet) et se deroule au fil du temps.

La structure temporelle est une caracteristique importante du dataset : la temperature de chauffe augmente progressivement depuis la temperature ambiante (environ 15 degC) jusqu'a la temperature cible du reacteur (ProcessTemperature), puis reste stable au plateau de reaction. La production de H2 suit cette dynamique thermique.

*Tableau 1: Statistiques descriptives du dataset de gazeification*

| Caracteristique            | Valeur                   |
|----------------------------|--------------------------|
| Nombre total de mesures    | 3 748 lignes             |
| Nombre d'expériences       | 59 groupes experimentaux |
| Experiences TWTS           | 36 experiences (61 %)    |
| Experiences Leather scraps | 23 experiences (39 %)    |
| H2 minimum                 | 0.0 vol%                 |
| H2 maximum                 | 37.5 vol%                |
| H2 moyen                   | 13.6 vol%                |
| H2 mediane                 | 12.8 vol%                |
| Valeurs manquantes         | 0 (dataset complet)      |
| Doublons                   | 0                        |

## 2.2 Description des Variables Originales

Le dataset original contient 9 colonnes (8 variables explicatives + 1 variable cible). Le tableau ci-dessous decrit chaque variable :

Tableau 2: Variables originales du dataset

| Variable           | Type         | Description                         | Unites   |
|--------------------|--------------|-------------------------------------|----------|
| Time               | Numerique    | Instant de mesure dans l'experience | min      |
| Temperature        | Numerique    | Temperature de chauffe mesuree      | degC     |
| ProcessTemperature | Numerique    | Temperature cible du reacteur       | degC     |
| AgentType          | Categorielle | Type d'agent gazeifiant             | Air / O2 |
| AgentFlow          | Numerique    | Debit de l'agent gazeifiant         | L/min    |
| SampleType         | Categorielle | Type de dechet gazefie              | --       |
| CatalystType       | Categorielle | Type de catalyseur utilise          | --       |
| CatalystRatio      | Numerique    | Proportion de catalyseur            | %        |
| Hydrogen           | Numerique    | Taux H2 produit (variable cible)    | vol%     |

## 2.3 Nettoyage et Preparation des Donnees

Avant d'entrainer les modeles, une etape de nettoyage et de preparation des donnees a ete effectuee. Les operations realisees sont les suivantes :

- Lecture du fichier CSV avec le bon separateur (point-virgule)
- Suppression des espaces en debut et fin dans les colonnes textuelles
- Verification des valeurs manquantes : aucune valeur manquante detectee
- Verification des doublons : aucun doublon detecte
- Correction des valeurs H2 negatives : remplacees par 0.0
- Creation de la colonne Experiment\_Group : regroupement des mesures par experience
- Tri des donnees par experience puis par temps (Time)
- Sauvegarde dans le fichier data\_clean.csv

## 2.4 Analyse Exploratoire

Avant de passer a la modelisation, une analyse exploratoire des donnees a ete realisee pour comprendre la distribution de la variable cible et les relations entre les variables.




Figure 1: Distribution du H2 dans le dataset (gauche) et comparaison par type de dechet (droite)

On observe que la distribution du H2 est asymetrique a droite, avec une concentration importante de valeurs entre 0 et 20 vol%. Le boxplot montre que les deux types de dechets ont des distributions de H2 similaires, avec une mediane legerement plus elevee pour les Leather scraps.

A blue horizontal banner with a scroll-like design, featuring a vertical strip on the left and a small circular detail on the right.

## **CHAPITRE 3 : FEATURE ENGINEERING**

### 3.1 Motivation

Les 8 variables brutes du dataset ne capturent pas directement l'energie thermique cumulee au cours du temps, qui est le facteur physique dominant de la production de H2. En effet, le processus de gazeification est fondamentalement dependant de l'historique thermique de l'experience : deux mesures a la meme temperature mais a des instants differents ne correspondent pas au meme etat de gazeification.

Pour remedier a cela, nous avons cree 13 nouvelles variables derivees qui encodent cette dynamique thermique. Le nombre total de features passe ainsi de 8 a 24 (21 numeriques + 3 categorielles).

### 3.2 Variables Derivees Creees

Tableau 3:: Variables creees par feature engineering (13 nouvelles variables)

| No. | Variable              | Formule / Calcul          | Signification physique       |
|-----|-----------------------|---------------------------|------------------------------|
| 1   | Cumul_Temp            | cumsum(Temperature)       | Energie thermique cumulee    |
| 2   | Thermal_Work          | Temperature x Time        | Travail thermique instantane |
| 3   | Temp_squared          | Temperature^2             | Effet non-lineaire (T)       |
| 4   | Cumul_Temp_squared    | Cumul_Temp^2              | Energie cumulee au carre     |
| 5   | Relative_Time         | Time / max(Time)          | Avancement relatif           |
| 6   | Thermal_Acceleration  | Thermal_Work/(Time+0.1)   | Vitesse de montee T          |
| 7   | Relative_Severity     | Relative_Time x ProcTemp  | Severite thermique rel.      |
| 8   | Agent_Intensity       | AgentFlow x ProcTemp      | Intensite de l'agent         |
| 9   | Kinetic_Agent_Density | AgentFlow x Relative_Time | Densite cinetique            |
| 10  | Temp_Norm_in_Run      | (T-Tmin)/(Tmax-Tmin)      | T normalisee dans experience |
| 11  | Temp_mean_run         | mean(T) du groupe         | Temp. moyenne experience     |
| 12  | Temp_max_run          | max(T) du groupe          | Temp. max experience         |
| 13  | Temp_std_run          | std(T) du groupe          | Variabilite thermique        |

### 3.3 Analyse des Correlations

Pour evaluer la pertinence des nouvelles features, nous avons calcule les coefficients de correlation de Pearson entre chaque variable et la variable cible H2.




Figure 2: Correlation des features avec la variable cible H2 (coefficient de Pearson)

La figure montre que les features dérivées de la température ont les corrélations les plus fortes avec H2. En particulier, Temp\_squared ( $r = 0.691$ ) et Thermal\_Acceleration ( $r = 0.689$ ) présentent des corrélations significativement plus élevées que la Température brute seule, ce qui justifie l'effort de feature engineering.



## **CHAPITRE 4 : MODELISATION MACHINE LEARNING**

## **4.1 Stratégie de Validation : GroupKFold**

Un aspect crucial de ce projet est le choix de la stratégie de validation croisée. Le dataset est une série temporelle : toutes les mesures d'une même expérience sont corrélées entre elles. Si on utilise une validation croisée classique (K-Fold standard), des mesures du même groupe peuvent se retrouver à la fois dans le train et dans le test, ce qui entraîne une fuite de données (data leakage) et une surestimation des performances.

Pour éviter ce problème, nous avons utilisé GroupKFold : cette méthode garantit que toutes les mesures d'une expérience restent entières soit dans l'ensemble d'entraînement, soit dans l'ensemble de test, jamais dans les deux. Nous avons utilisé 5 folds pour le modèle global et 3 folds pour le modèle Leather scraps (moins d'expériences disponibles).

## **4.2 Algorithmes Etudiés**

Trois algorithmes de type forêt aléatoire ont été comparés dans ce projet. Ces méthodes d'ensemble sont particulièrement adaptées aux données de taille modérée avec beaucoup de features, comme c'est le cas ici.

- Random Forest : forêt aléatoire classique avec sélection optimale du seuil
- Extra Trees (Extremely Randomized Trees) : randomisation complète des seuils
- XGBoost : gradient boosting sur arbres de décision

Chaque algorithme a été optimisé par recherche aléatoire d'hyperparamètres (RandomizedSearchCV) avec 30 itérations et validation GroupKFold.


## **4.3 Sélection des Hyperparamètres**

Les meilleurs hyperparamètres obtenus pour l'Extra Trees Regressor (modèle global) sont les suivants :

Tableau 4: Hyperparametres optimaux du modele Extra Trees Global

| Hyperparametre    | Valeur optimale | Role                                  |
|-------------------|-----------------|---------------------------------------|
| n_estimators      | 1 000           | Nombre d'arbres de decision           |
| max_depth         | 10              | Profondeur maximale de chaque arbre   |
| min_samples_split | 2               | Nombre minimum pour diviser un noeud  |
| min_samples_leaf  | 3               | Nombre minimum de samples par feuille |
| max_features      | 0.8             | Fraction des features par division    |

## 4.4 Résultats Comparatifs



3: Comparaison des trois algorithmes ML : R2, MAE et RMSE (GroupKFold 5-fold)

Tableau 5: Comparaison des algorithmes ML (GroupKFold 5-fold, Extra Trees global)

| Algorithme    | R2 Test | MAE (vol%) | RMSE (vol%) | Stabilite (Std R2) | Decision   |
|---------------|---------|------------|-------------|--------------------|------------|
| Random Forest | 0.8205  | 3.191      | 4.662       | 0.067              | Non retenu |
| Extra Trees   | 0.8280  | 3.095      | 4.556       | 0.055              | RETENU     |
| XGBoost       | 0.7990  | 3.391      | 4.933       | 0.058              | Non retenu |

L'Extra Trees Regressor est retenu car il offre le meilleur compromis entre R2, MAE et stabilite. Sa randomisation complete des seuils de coupure le rend plus robuste au bruit experimental typique des mesures de gazeification en laboratoire.




Figure 4: R2 par fold (GroupKFold 5-fold) pour l'Extra Trees Regressor global

Tableau 6: Resultats detailles par fold -- Extra Trees Global (GroupKFold 5-fold)

| Fold   | Experiences test | R2     | MAE (vol%) | RMSE (vol%) |
|--------|------------------|--------|------------|-------------|
| Fold 1 | ~12 exp.         | 0.8941 | 2.467      | 3.413       |
| Fold 2 | ~12 exp.         | 0.8459 | 2.946      | 4.207       |
| Fold 3 | ~12 exp.         | 0.8853 | 2.451      | 3.415       |
| Fold 4 | ~12 exp.         | 0.7893 | 3.824      | 5.558       |
| Fold 5 | ~11 exp.         | 0.7515 | 3.778      | 5.663       |
| GLOBAL | 59 exp.          | 0.8280 | 3.095      | 4.564       |

On remarque que les folds 4 et 5 ont des performances inferieures. Cela indique que certains groupes d'experiences sont plus difficiles a predire, probablement parce que leurs conditions sont plus eloignees des autres experiences dans l'espace des features.




Figure 5: H2 reel vs predict sur tout le dataset (gauche) et distribution des residus (droite)

## 4.5 Analyse du Sur-apprentissage (Overfitting)

Une problematique importante dans ce projet est le sur-apprentissage. Avec seulement 59 experiences distinctes et 24 features, le risque que le modele memorise les donnees d'entrainement au lieu d'apprendre les relations generales est eleve.




Figure 6: Diagnostic du sur-apprentissage : comparaison R2 Train vs R2 Test

Tableau 7: Diagnostic du sur-apprentissage -- comparaison Train vs Test

| Metrique   | Donnees Train | Donnees Test (CV) | Ecart (overfitting) |
|------------|---------------|-------------------|---------------------|
| R2         | 0.9745        | 0.8280            | 0.1465              |
| MAE (vol%) | 1.10          | 3.095             | x 2.8               |

L'ecart de 0.1465 entre le  $R^2$  train et le  $R^2$  test confirme un sur-apprentissage modéré. Les causes principales identifiées sont : le dataset réduit (59 expériences), le nombre élevé de features (24) par rapport au nombre d'expériences, et la complexité du modèle ( $\text{max\_depth}=10$ , 1 000 arbres). Plusieurs solutions ont été testées (régularisation plus forte, réduction de features) mais l'amélioration reste limitée par la taille intrinsèque du dataset.

## **CHAPITRE 5: APPROCHE HYBRIDE : DEUX MODELES SPECIALISES**

## **5.1 Motivation**

Les boues textiles (TWTS) et les chutes de cuir (Leather scraps) ont des compositions chimiques différentes : teneurs en cellulose, lignine, protéines et polymères synthétiques varient significativement. Un modèle unique doit donc faire des compromis entre les deux matériaux. L'idée est d'entraîner un modèle dédié à chaque type de déchet pour potentiellement améliorer la précision.

## **5.2 modèle TWTS (Global)**

Pour les boues textiles (TWTS), nous avons d'abord entraîné un modèle dédié en utilisant uniquement les 36 expériences TWTS. Étonnamment, les résultats montrent que ce modèle TWTS-seul ( $R^2=0.785$ ) est moins performant que le modèle global entraîné sur les deux types de déchets ( $R^2=0.828$ ). Ce phénomène s'explique par un effet de transfert d'apprentissage : les patterns communs entre TWTS et Leather scraps (effet de la température, du débit d'agent) aident le modèle global à mieux généraliser pour TWTS.

Nous avons donc décidé de conserver le modèle global pour les prédictions TWTS.

## **5.3 Modèle Leather Scraps (Specialise)**

Pour les chutes de cuir (Leather scraps), le modèle spécialisé entraîne sur les 23 expériences disponibles avec 3-fold GroupKFold donne un  $R^2=0.859$ , supérieur au modèle global ( $R^2=0.828$ ). Le comportement thermochimique spécifique du cuir (notamment sa composition en protéines) est suffisamment distinct pour justifier un modèle dédié. La variable SampleType est exclue de ce modèle puisqu'il ne traite qu'un seul type de matériau.

## **5.4 Comparaison des Approches**




Figure 7 : Comparaison R2 (gauche) et MAE (droite) selon l'approche adoptée

Tableau 8: Comparaison des approches : global vs modeles sepes vs hybride

| Approche           | Materiau       | Exp. | R2 Test | MAE (vol%) | Conclusion |
|--------------------|----------------|------|---------|------------|------------|
| Global (reference) | TWTS + Leather | 59   | 0.828   | 3.095      | Reference  |
| TWTS seul          | TWTS seul      | 36   | 0.785   | 3.530      | Moins bon  |
| Leather specialise | Leather seul   | 23   | 0.859   | 2.630      | Meilleur   |
| Hybride (retenu)   | Les deux       | 59   | ---     | ---        | RETENU     |

L'approche hybride finale retenue est la suivante : pour une prediction TWTS, on utilise le modele global (model\_extra\_trees.pkl,  $R^2=0.828$ ,  $MAE=3.095$  vol%). Pour une prediction Leather scraps, on utilise le modele specialise (model\_leather.pkl,  $R^2=0.859$ ,  $MAE=2.630$  vol%).

A blue horizontal banner with a scroll-like design, featuring a vertical strip on the left and a small circular detail on the right.

## **CHAPITRE 6 : CORRECTION DES BUGS ET VALIDATION**

## 6.1 Bugs Identifies

Lors des premiers tests de l'application, les predictions ne correspondaient pas aux valeurs reelles du dataset. Apres investigation, quatre bugs critiques ont ete identifies dans la fonction de calcul des features de l'application. Le probleme fondamental etait que le modele a ete entraine sur des series temporelles avec des features calculees sur toute l'experience (groupe), mais dans l'application, l'utilisateur entre un seul point temporel, rendant ces calculs impossibles ou incorrects.

Le tableau ci-dessous presente les quatre bugs identifies et leurs corrections :

*Tableau 9: Bugs identifies dans le calcul des features de l'application Streamlit*

| Feature       | Valeur Bugguee                | Valeur Correcte                         | Impact   |
|---------------|-------------------------------|-----------------------------------------|----------|
| Cumul_Temp    | $T \times t$ (= Thermal_Work) | cumsum(T) de l'experience               | CRITIQUE |
| Temp_Norm     | $(T-6)/(1000-6)$              | $(T-T_{min})/(T_{max}-T_{min})$ par run | FORT     |
| Temp_mean_run | Temperature courante T        | mean(T) de l'experience                 | MOYEN    |
| Temp_std_run  | 0.0 (toujours zero)           | std(T) de l'experience                  | MOYEN    |

## 6.2 Solution : Systeme de Lookup Exact

La correction principale consiste a charger le dataset d'entrainement (data\_clean.csv avec les features calculees) dans l'application et a effectuer une recherche exacte des conditions entrees par l'utilisateur. Deux modes de fonctionnement ont ete implements :

**Lookup exact (indicateur vert)** : si les conditions entrees correspondent exactement a une ligne du dataset, les features reelles sont utilisees directement. MAE observee : ~1.5 vol%.

**Approximations corrigees (indicateur orange)** : si les conditions ne correspondent a aucune ligne du dataset (nouvelles conditions), des approximations basees sur les formules corrigees sont calculees. MAE observee : ~3.0 vol%.

Cette approche a permis de reduire l'erreur de prediction de 57% (MAE avant correction = 3.48 vol%, MAE apres = 1.48 vol%).

### 6.3 Validation sur 10 Exemples Reels

Pour valider le fonctionnement de l'application corrigée, dix exemples reels issus du dataset ont été sélectionnés, couvrant les deux types de déchets, différentes températures, agents gazeux et catalyseurs.

Tableau 10: Résultats de validation sur 10 exemples reels du dataset

| Ex. | Déchet  | Time | T (degC) | ProcT | Agent | Catalyseur | %Cat | H2 Reel | H2 Predit | Erreur   |
|-----|---------|------|----------|-------|-------|------------|------|---------|-----------|----------|
| 1   | TWTS    | 38   | 900      | 1000  | Air   | Al-Ni      | 10   | 34.74   | 25.15     | 9.59 (*) |
| 2   | TWTS    | 34   | 700      | 700   | Air   | No Cat.    | 0    | 17.00   | 15.04     | 1.96     |
| 3   | TWTS    | 41   | 900      | 900   | O2    | No Cat.    | 0    | 37.45   | 34.04     | 3.41     |
| 4   | TWTS    | 46   | 700      | 700   | Air   | Marble     | 20   | 26.00   | 23.74     | 2.26     |
| 5   | TWTS    | 31   | 823      | 900   | Air   | Al-Ni      | 2.5  | 24.88   | 24.24     | 0.64     |
| 6   | Leather | 22   | 754      | 900   | Air   | Marble     | 15   | 26.61   | 26.98     | 0.37     |
| 7   | Leather | 19   | 702      | 800   | Air   | Al-Ni      | 10   | 15.25   | 15.75     | 0.50     |
| 8   | Leather | 22   | 754      | 900   | Air   | Al-Ni      | 10   | 25.82   | 26.84     | 1.02     |
| 9   | Leather | 26   | 800      | 900   | Air   | Al-Ni      | 5    | 30.68   | 27.86     | 2.82     |
| 10  | Leather | 16   | 510      | 800   | O2    | No Cat.    | 0    | 11.28   | 10.61     | 0.67     |

(\*) Exemple 1 : le temps saisi dans l'application était 32 au lieu de 38. Cette erreur de saisie a empêché le lookup exact de trouver la correspondance, entraînant une erreur plus grande.





Figure 8: Comparaison H2 reel vs predit (gauche) et erreur absolue par exemple (droite)

Les résultats montrent que 9 exemples sur 10 ont une erreur inférieure à 3.5 vol% (MAE théorique du modèle). Le MAE observé sur les 10 exemples est de 1.74 vol%, ce qui est nettement inférieur au MAE théorique de 3.09 vol%, confirmant l'efficacité du système de lookup exact.



*Figure 9: Importance des features -- Top 10 (Extra Trees Global, Gini Importance)*

## **CHAPITRE 7: APPLICATION WEB STREAMLIT**

## 7.1 Architecture de l'Application

Pour rendre les predictions accessibles, une application web interactive a ete developpee avec le framework Streamlit. Cette application charge automatiquement le modele approprie en fonction du type de dechet selectionne par l'utilisateur, et utilise le systeme de lookup exact presente dans le chapitre precedent.

L'architecture generale de l'application est la suivante :

- Chargement du dataset data\_clean.csv avec calcul de toutes les features
- Chargement des deux modeles : model\_extra\_trees.pkl et model\_leather.pkl
- Saisie des conditions operatoires dans la barre laterale (sidebar)
- Recherche exacte dans le dataset -> si trouvee : features exactes (indicateur vert)
- Sinon : calcul des approximations corrigees (indicateur orange)
- Routage vers le bon modele selon SampleType
- Affichage du H2 predit avec la plage probable (prediction +/- MAE)

## 7.2 Description des Fonctionnalités

### 7.2.1 Onglet Prediction

L'onglet principal permet de saisir toutes les conditions operatoires : temperature de chauffe (Temperature), temperature du reacteur (ProcessTemperature), instant de mesure (Time), type d'agent gazeifiant, debit d'agent, type de dechet, type de catalyseur et proportion de catalyseur. Le modele calcule alors le taux de H2 predit avec la plage probable (prediction +/- MAE). Un indicateur de couleur (vert ou orange) precise si les features utilisees sont exactes ou approximees.

### 7.2.2 Onglet Historique

L'onglet historique enregistre toutes les predictions effectuees au cours de la session. Il affiche un tableau recapitulatif avec les conditions entrees et les predictions obtenues. Il permet egalement d'exporter l'historique au format CSV et affiche des statistiques rapides (meilleure prediction, moyenne, minimum).

### 7.2.3 Onglet Dashboard

L'onglet dashboard affiche quatre graphiques interactifs : l'évolution du H2 prédit par expérience enregistrée, la relation entre le H2 prédit et la température de chauffe, la distribution du H2 par type d'agent gazeifiant (boxplot), et l'évolution temporelle du H2 dans la session avec la bande de confiance  $\pm$  MAE.

### 7.3 Bug Corrige dans l'Interface

Lors du développement, une erreur Python a été corrigée dans la fonction de trace du boxplot du dashboard :

```
AVANT (erreur) :  
    ax.boxplot(data, labels=agents, ...)  
  
APRES (correct) :    ax.boxplot(data,  
    tick_labels=agents, ...)
```

Cette erreur était due à un changement de nom du paramètre 'labels' en 'tick\_labels' dans les nouvelles versions de matplotlib. Elle provoquait une exception `TypeError` qui bloquait l'affichage du dashboard.

Tableau 11: Fonctionnalités implémentées dans l'application Streamlit

| Fonctionnalité         | Description                               | Etat        |
|------------------------|-------------------------------------------|-------------|
| Prediction H2          | Saisie des paramètres + H2 prédit + plage | Fonctionnel |
| Indicateur vert/orange | Lookup exact vs approximation             | Fonctionnel |
| Tableau features       | Valeurs réelles des 24 features utilisées | Fonctionnel |
| Historique session     | Enregistrement + tableau + stats          | Fonctionnel |
| Export CSV             | Téléchargement de l'historique            | Fonctionnel |
| Dashboard graphiques   | 4 graphiques interactifs                  | Fonctionnel |
| Routage hybride        | Sélectionne le bon modèle auto.           | Fonctionnel |

## CONCLUSION GENERALE

Ce projet de fin de module nous a permis de developper un systeme complet de prediction du taux d'hydrogene produit par gazeification de dechets industriels, en couvrant l'ensemble de la chaine : de la preparation des donnees jusqu'au deploiement d'une application web.

Les principaux resultats obtenus sont les suivants. L'Extra Trees Regressor s'est avere le meilleur algorithme, avec un  $R^2=0.828$  pour les predictions sur TWTS et  $R^2=0.859$  pour les Leather scraps. L'approche hybride (deux modeles specialises) a permis d'ameliorer la precision sur les Leather scraps de +3.1% par rapport au modele global. Le feature engineering a joue un role determinant : la feature Cumul\_Temp (energie thermique cumulee) s'est revelee la variable la plus importante, ce qui est coherent avec la physique du procede.

Quatre bugs critiques dans le calcul des features ont ete identifies et corriges, reduisant l'erreur de prediction de 57% dans l'application. La validation sur 10 exemples reels montre que 9 predictions sur 10 sont dans la marge d'erreur acceptable, avec un MAE observe de 1.74 vol%, nettement inferieur au MAE theorique de 3.09 vol%.

Les principales limitations de ce projet sont la taille moderee du dataset (59 experiences) qui entraine un sur-apprentissage modere (ecart  $R^2$  Train/Test = 0.146), et la restriction du modele au domaine des donnees experimentales ( $H_2$  max = 37.5 vol%, reacteur a lit fixe uniquement).

Comme perspectives d'amelioration, nous proposons d'enrichir le dataset en ajoutant de nouvelles experiences experimentales (objectif : 150+ experiences), d'inclure la vapeur d'eau comme agent gazeifiant pour atteindre des taux de  $H_2$  superieurs a 40 vol%, et d'etendre le modele a d'autres types de dechets industriels (papier, plastique, biomasse agricole).

## BIBLIOGRAPHIQUES

- [1] Breiman, L. (2001). Random Forests. Machine Learning, 45(1), 5-32.
- [2] Geurts, P., Ernst, D., Wehenkel, L. (2006). Extremely Randomized Trees. Machine Learning, 63(1), 3-42.
- [3] Chen, T., Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD, 785-794.
- [4] Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- [5] McKinney, W. (2010). Data Structures for Statistical Computing in Python. Proceedings of the 9th Python in Science Conference, 51-56.
- [6] Basu, P. (2018). Biomass Gasification, Pyrolysis and Torrefaction: Practical Design and Theory. Academic Press, 3rd edition.
- [7] Molina-Moreno, V. et al. (2017). Analysis of Circular Economy in European Chemical Industries. Sustainability, 9(8), 1452.
- [8] Peduzzi, E. et al. (2014). Gasification of woody biomass : Process design and optimization. Energy, 67, 45-55.